

무엇을, 왜 추출했나

목표: 뉴스 제목에서 기업에 연결되는 사건과 기대 대비 정보를 구조화해, 기존 모델의 다음 거래일 등락 분류에 도움이 되는지 검증한다.

EDA와 멘토 답변을 연결한 선택

뉴스 본문 결측이 많아 제목을 사용했다. 종목 태그가 있어도 다른 기업 기사·사용법·광고가 섞였고, 논조만으로는 대상 기업에 어떤 사건이 생겼는지 구분하기 어려웠다. 멘토의 제안대로 단순 감성보다 기업 연결, 사건, 기대 대비 비교를 우선했다.

피쳐 묶음	뽑는 내용 / 선택 이유
관련성	direct:indirect 등으로 대상 기업과 연결되는지 판단. 다른 기업의 호재가 대상 기업의 호재로 섞이는 것을 줄인다.
기대 대비 비교 — 우선 평가	above / below / in_line / mixed / unknown. 실적·전망이 기대를 상회·하회했는지 구분한다. 단순 전년 대비 성장과 시장 기대 대비 성과를 분리한다.
사건 유형 — 추가 검증	실적, 기업 전망, 비용, 규제·소송, 제품, 투자, 지분 변화, 자금조달, M&A, 사업 이전, 경영진, 기타의 12종. 가격에 영향을 줄 수 있는 경로를 구분한다.
사건 상태·지분 방향 — 추가 검증	발생·발표 계획·가능성·의혹·대기·불명과 지분 증가·감소. 의혹을 확정 사실로, 기관의 지분 매입을 기업 인수로 오해하지 않도록 한다.

주가 반응·투자 의견·원문 근거는 별도 검수 정보로 보존한다. 중요도·전반적 긍부정 점수·새로움은 이번 최종 집계에 넣지 않았다. Reddit은 이번 추출에 포함하지 않았다.

프롬프트를 바꾼 이유 ①

v1에서 v6까지 발전한 흐름이다. 아래 버전별 설명은 대화의 사례와 수정 취지를 요약한 것이며, 모든 과거 프롬프트 원문의 정확한 차이표는 아니다.

v1 → v2: 외부 지식으로 빈칸을 채우지 않기

초기 결과는 MSFT 태그가 붙은 OpenAI 기사에 기업 관계를 덧붙이거나, Anduril의 헤드셋 사업 인수를 “Microsoft의 직접 손실”이라고 설명했다. 제목만으로 확인되지 않는 판단이었다.

수정: 제목에 있는 정보만 사용하고, 기업 관련성·방향·중요도에 근거를 요구했다. 근거가 없으면 unknown을 허용했다. 손실이나 중요도를 추측하는 대신 판단을 보류하도록 바꿨다.

v2 → v3: 태그와 실제 기업 관련성을 분리하기

MSFT로 수집된 표본에 CVGI·SoftBank 실적, Gmail 내보내기 사용법, 할인 광고 등이 포함됐다. 종목 태그를 사실상 정답으로 쓰면 다른 기업의 실적까지 MSFT 피처가 된다.

수정: 기업명과 연결 근거를 확인하고, 근거 부족 시 관련성을 unknown으로 보정했다. 관련성이 확인되지 않은 기사에서 사건·기대 비교를 대상 기업 정보로 집계하지 않도록 했다.

v3 → v4: 근거 없음과 중립을 구분하기

“might make the Xbox handheld”는 가능성 근거가 있지만 기대 상회 근거는 없다. 모든 칸이 채워져야 하는 것은 아니었다. 반대로 “beat estimates”는 실제 기대 비교 근거가 된다.

수정: 판단 항목마다 근거를 분리하고, 불확실성 표현과 기대 비교 표현을 구별했다. 빈 근거는 중립이 아니라 해당 판단을 뒷받침할 정보가 없다는 뜻으로 다뤘다.

발표 포인트: unknown을 줄이는 것보다, 근거 없는 확신을 줄이는 것이 먼저였다.

프롬프트를 바꾼 이유 ②

후반 수정의 핵심은 “사업 정보”, “이미 일어난 주가 반응”, “투자 의견”을 섞지 않는 것이다.

v4 → v5: 긍정과 부정의 근거를 각각 확인

“AI business growing 175% … stock falling”에서 사업 성장과 주가 하락이 함께 추출됐다. “Stocks Soaring Despite Dilution”도 가격 상승과 희석을 한 방향 점수로 합치기 어려웠다.

수정: 긍정·부정 근거를 따로 확인했다. 그 결과 주가 반응을 사업상 호재·악재와 섞는 한계가 드러났고, 방향 점수 자체를 재검토했다.

v5 → v6: 구조화된 사건과 상태로 전환

확인한 사례	v6에서 적용한 판단
C02: 상승 여력이 있다는 투자 의견	사업 사건을 만들지 않고 투자 의견과 주가 반응으로 별도 저장.
C03: AI 성장 + 주가 하락	사업 지표는 earnings, stock falling은 주가 반응. 전체 방향 점수는 생성하지 않음.
C05 / C06: Might Make / accused of	제품 가능성은 proposed_possible, 의혹은 alleged. 발생 확정으로 바꾸지 않음.
C09: Azure 성장률 below 40%	40%라는 수치 기준은 시장 기대가 아님. 기대 비교 근거가 없으면 unknown.
C12: 기관이 AMD 보유 지분 축소	ownership_change + decrease. AMD 기업 자체의 사업 투자·인수로 해석하지 않음.

남은 한계: 문법·인용 검증은 의미의 정확성을 보장하지 않는다. “to incur”의 상태, 구조조정과 M&A, 실적 발표 전 기사 등은 여전히 오분류 가능성이 있어 사건·상태 피쳐는 추가 검증 대상으로 둔다.

중간에 기대 비교만 추출하는 별도 코드가 실행됐으나 v6와 다른 실험이다. 최종 전달 데이터에는 혼합하지 않고 v6 결과만 사용한다.

어떻게 실제로 추출했나

전체 뉴스에 API를 호출하지 않고, 비용 안에서 검증 가능한 후보를 선택했다. 이 선택 때문에 결과는 “필터를 통과한 기사”에 대한 피처다.

단계	실행 방식
① 시간 범위	TRAIN 대상 거래일 376일 × 50종목 = 18,800개 종목·날짜. 대상일은 2024-08-14~2026-02-12. 전일 장 마감~예측일 개장 전 참에서 known_at < cutoff를 지킨다.
② 후보 선택	expect / estimate / consensus / forecast 계열 표현과 기업명 필터 적용. 기업명 확인 전 24,593건 → 확인 후 4,103건, 2,057개 종목·날짜, 45종목.
③ 중복 통합·호출	같은 기업·제목을 날짜 간 재사용하면 약 3,962개 고유 요청. Gemini에 v6 프롬프트와 구조화된 출력 스키마를 전달한다.
④ 검증·캐시	응답 형식과 원문 인용을 검사. 원래 응답과 검증 결과를 분리 저장하고 완료 응답은 재호출하지 않는다.
⑤ 일별 집계	기사 단위 사건·기대 비교를 종목·예측 대상일별 비율로 변환. 분모와 처리 상태를 함께 저장한다.

오류는 전체 중단 대신 개별 보류

첫 309회 호출에서 검증 실패 10건으로 중단됐다. 8건은 연속 공백, 1건은 대소문자 차이였고, DELL 1건은 떨어진 단어를 하나의 인용처럼 합친 경우였다. 공백·대소문자만 유일하게 매칭되면 원문 표현으로 복구하고, 나머지는 제외한다.

v6 프롬프트는 유지했다. 이후 “실패 10건이면 중단” 조건을 제거해 실패 응답만 보관하며 이어가도록 했다. 비용 상한은 유지한다. 실패 건은 뉴스 없음이나 중립으로 바꾸지 않는다.

결과와 최종 전달물

현재 확인된 것은 추출 진행 상황과 CSV 생성 방식이다. 실제 최종 CSV의 완료 건수·피쳐 분포·모델 성능은 아직 확인되지 않았다.

현재 확인된 진행 상황

최신 화면: 이전 309회 + 재시작 후 375회 = 약 684회 요청 시도(약 17%). 비용·보류 추정액은 583원. 이는 성공 건수나 실제 청구액이 아니다. 전체 약 3,962개 요청 기준 약 3,278개가 남았다.

ZIP 안의 파일	내용 / 재은이의 사용 방법
train_news_v6_features.csv	종목·날짜별 피쳐. symbol + target(예측 대상 거래일)로 모델 데이터와 결합. feature_*는 해당 날짜 후보가 전부 성공한 경우만 값 제공.
news_v6_valid_articles.csv	검증 통과 기사, 기대 비교·원문 근거, 사건 JSON. 오류 사례 검수용이며 원문 컬럼을 그대로 모델에 넣지 않는다.
news_v6_excluded_rows.csv	실패 또는 미처리 후보 목록. 원본 뉴스 행을 삭제한 것이 아니라 결과 집계에서 제외한 기록.
README.txt	컬럼 의미, 비율 분모, 결측·평가·제출 시 유의점. ZIP 이름은 chaemin_news_v6_handoff.zip.

재은이가 실제 모델에 넣는 순서

1. llm_pending_n이 0인지 확인하고 실패·완료 비율을 점검한다.
2. 우선 feature_relevant_share와 feature_surprise_*만 추가해 동일 fold·모델로 기존 점수와 비교한다. 사건·상태 피쳐는 별도 추가 실험한다.
3. observed_*는 성공 기사만의 비율이므로 부분 처리 편향에 주의한다. feature_*의 빈칸을 자동으로 0으로 바꾸지 않는다.

분모: relevant_share는 성공 기사 수, surprise/event/state/ownership은 관련 기사 수. 후보 없음·소스 없음·실패·unknown은 다른 상태다. 다중 사건 비율의 합은 1을 넘을 수 있다.

최종 제출물은 ZIP + 재현용 Colab 코드(v6 프롬프트·검증·집계)다. 현재 TRAIN CSV만으로 새 날짜를 처리할 수 없으므로, 제출 시에는 API 없이 동작하는 피쳐 생성 방식도 재은이와 통합해야 한다. 피쳐의 성능 개선 효과는 아직 검증 전이다.