

B 파트 피처 정리 (정형 데이터: daily · price · earnings · analyst)

작성 2026-10-02, 갱신 2026-10-03 · 민영 · 평가는 재은님 폴드(lab/folds.json, val 60거래일 × 4, embargo 12, 처음 보는 종목 10개) 기준

결론 먼저

	4폴드 평균 score	비고
원래 갭 규칙 (재은님 기준선, eda/cv_check_ovn_gap.py)	0.433	출발점
gap_z 규칙 (gap ÷ vol20 로 경계)	0.444	4폴드 모두 상승 (+0.010 +0.027 +0.010 +0.001)
gap_z 규칙 + ext_range_z	0.447	4폴드 모두 상승 (gap_z 대비 +0.002 +0.005 +0.001 +0.003), fold4 0.515, 처음 보는 종목 0.363
(참고) LightGBM + B 피처 26개(V1), 급등락 34% 디코딩	0.417	

폴드별	fold1	fold2	fold3	fold4	평균
원래 갭 (재은님 기준선)	0.423	0.404	0.391	0.511	0.433
gap_z	0.433	0.431	0.401	0.512	0.444
gap_z + ext_range_z	0.434	0.436	0.402	0.515	0.447

쓰는 피처: gap_z, ext_range_z 두 개. 나머지 100개는 아래 근거로 뺐음.

숫자 기준: 위 표는 재은님 기준선과 같은 경계 후보(1~.99)로 낸 최종 값. 아래 2~4절의 실험(1~12차)은 경계 후보 .5~.99 로 돌려서 gap_z 규칙 0.438, + ext_range_z 0.444 가 기준임. 후보를 넓히면 모든 규칙이 함께 오르고(원래 갭 0.423 → 0.433), 피처 사이의 비교 결과는 같음.

1. 피처 추출 방식

시점 원칙 (누수 방지)

- 모든 데이터는 day.daily / day.price / day.earnings / day.analyst 로만 읽음 → known_at < 대상일 09:30 인 행만 나옴.
- 피처 표는 lab.cv.feature_table 로 만들어서 guard 가 씌워진 상태에서만 계산. 누수 검사 통과.
- 종목 이름·날짜를 코드에 넣지 않음. 종목마다 크기가 다른 값은 자기 변동성(vol20)으로 나눈 z값으로 만듦.
- 시장 값 = 그날 daily 에 보이는 종목들의 동일가중 평균.

시간 구간

이름	구간	쓰는 곳
기준일	대상일 직전 거래일 (증가 16:00 확정)	일봉 피처 전부
장후 (post)	기준일 16:00 ~ 20:00	post_ret, post_n
장전 (pre)	대상일 04:00 ~	pre_move, pre_late
시간외 전체	기준일 16:00 이후 post + pre 봉	gap, ext_range_z 등

이름	구간	쓰는 곳
마지막 시간외 봉	대상일 08:00 봉 (09:00 공개)	gap 의 "현재 가격"
밤사이 이벤트	기준일 16:00 ~ 대상일 09:30	earn_now, an_now_*

핵심 두 피쳐 계산

```
gap      = 마지막 시간외 봉 증가 ÷ 기준일 증가 - 1
vol120   = 최근 20거래일 일간 수익률 표준편차
gap_z     = gap ÷ vol120
ext_range_z = (시간외 봉 최고가 - 최저가) ÷ 기준일 증가 ÷ vol120
```

코드: `work/b/features/gapz_rule.py` 의 `build_gapz(day)` (전달용, 두 피쳐만). `work/b/features/features_b.py` 의 `build_b(day)` 에도 같은 값이 들어 있음.

결측

피쳐	결측률	결측 행 (A 폴드 전체 22,450행)
gap_z	0.22%	50
ext_range_z	0.22%	50

- 50행 전부 **기준일 2026-01-30(금) → 대상일 2026-02-02(월)** 하루, 50종목 모두. 그 밖의 날짜는 결측 없음.
- 원인은 **원본 price 데이터 누락**: 1/30 장후 봉 0개, 2/2 장전 봉 0개(평소 각 150개, 290개 안팎). 같은 이틀은 정 규장 봉도 평소의 1/5~1/2 수준. 일봉은 정상.
- 처리: 규칙에서는 갭이 없으면 포함(2). LightGBM 에 넣을 때는 결측 그대로 두면 됨 (따로 채울 필요 없음).
- `ext_range_z = 0` (시간외 봉이 하나뿐) 인 행은 없음.

최종 규칙

```
 $\tilde{x} = (\text{ext\_range\_z} - \text{train 중양값}) \div \text{train 표준편차}, \pm 5 \text{ 로 자름, 결측 } 0$ 
 $s = \text{gap\_z} \times \exp(-\lambda \cdot \tilde{x})$        $\lambda$ : train score 최대로 고름 (폴드마다 0.05~0.3). 실험(경계 후보 .5~)에서는
0.2 고정도 4폴드 모두 상승
경계  $a < b$ :  $|s|$  의 분위 [.1 .2 .3 .4 .5 .6 .7 .8 .85 .9 .95 .975 .99] 중 train score 최대인 쌍 (재은님 기준
선과 같은 후보)
 $s \geq b \rightarrow 4$  급상승 /  $s \geq a \rightarrow 3$  상승 /  $s \leq -a \rightarrow 1$  하락 /  $s \leq -b \rightarrow 0$  급하락 / 그 밖·결측  $\rightarrow 2$  포함
```

- 경계 a 가 작게 잡혀서(폴드마다 $|s|$ 하위 10% 수준) 포함은 거의 안 찍음 (50종목 중 3~5개). 점수에서 정답이 포함인 행은 가중치가 0 이라, train score 를 최대로 하면 이렇게 됨.

2. 선택 방법

평가

- 점수: `src.score` (가중 kappa 류, 0 = 우연). 처음 보는 10종목은 학습에서 빼고 val 에만.
- 비교 기준: gap_z 규칙. 모델이 있는 실험은 시드 3개 평균.
- 피쳐를 gap_z 에 붙이는 방식 세 가지 (피쳐는 train 기준 표준화):
- **더하기** $s = \text{gz} + \beta \cdot \sigma \cdot \tilde{x}$ — 방향 정보를 보탬
- **곱하기** $s = \text{gz} \cdot \exp(\beta \cdot \tilde{x})$ — 그날 갭을 얼마나 믿을지
- **같은방향** $s = \text{gz} \cdot \exp(\beta \cdot \tilde{x} \cdot \text{sign}(\text{gz}))$ — 피쳐가 갭과 같은 방향이면 더 믿음
- β 는 폴드마다 **train 으로만** 고름 (val 안 봄).

채택 기준 (실험 전에 정함)

- 1. 4폴드 평균 +0.005 이상
- 2. 4폴드 중 3폴드 이상 상승
- 3. fold4(2026-03~05, EDA 와 안 겹침)에서 하락 없음
- 4. **우연 기준선보다 커야 함:** 피쳐 값을 행 사이에서 무작위로 섞어 같은 절차를 돌리면, 225개 조합 중 1~4개가 기준 1~3을 통과하고 최대 +0.008 까지 나옴. 많이 시험할수록 우연 통과가 생기므로, 앞 실험에서 먼저 발견되고 (사전 근거) 부호가 4폴드 모두 같은 것만 인정.

3. 시도한 피쳐 (102개)

채택 (2개)

피쳐	정의	gap_z 규칙 대비	상승 폴드	방향 IC	크기 IC
gap_z	시간외 갭 ÷ vol20	기준 (원래 갭 규칙 대비 +0.016)	4	0.300	0.060
ext_range_z	(시간외 최고 - 최저) ÷ 종가 ÷ vol20, 곱하기 $\beta < 0$	+0.005	4	-0.027	-0.040

방향 IC·크기 IC = 날짜별 순위상관(피쳐, 다음날 수익률 / |수익률|) 평균.

적용하지 않은 것 (100개)

묶음	피쳐	뺀 이유
갭 변형	gap, abs_gap_z, gap_rel_z, gap_onz, gap_rank, mkt_gap, mkt_gap_z, new_idio_gap_z, gap_first_z, gap_drift_z, brk_z, rng_pos, ext_pos	gap_z 와 같은 정보이거나 더 약함
장전·장 후 흐름	post_ret, pre_move, pre_late, new_pre_z, new_post_z, new_agree3, post_n, pre_n, ext_n, new_ext_liq	갭의 일부라 이미 들어 있음
수익률·추세	ret1-5-20 (+ _z), rel_ret1_z, rel_ret5_z, gap_open1, intraday1, last_hour_z, dist_ma20_z, dist_ma50_z, rsi14, bb_pctb, macd_hist, streak, pos60, volu_ratio	방향 IC ± 0.03 이하, 효과 없음
변동성	vol5, vol20, vol60, vol_5_20, vol_20_60, atr14, range1, range1_z, bigfreq20, bigfreq60, beta60, absret1_z, big_yday	크기는 잘 맞힘(크기 IC 최대 0.29), 방향을 몰라 점수로 안 바뀜. vol20 은 gap_z 분모로 씀
시장 전체	mkt_ret1, mkt_ret5, mkt_vol20, mkt_absgap, gap_disp, rel_mkt20, follow_mkt20	폴드마다 부호가 바뀜 (직전 국면에만 맞음)
동종 종목·과거 적중	peer_gz, idio_gz, follow_sym60, hit_sym60	효과 없거나 넣으면 하락
밤사이 누적	ovn5_z, ovn20_z, intra20_z	효과 없음
전날 장 중·거래량	am_ret_z, pm_ret_z, pm_vol_rel, buy_press, vwap_dev_z, close_loc	효과 없음
실적	earn_now, earn_surprise_now, earn_prev, days_since_earn, last_surprise, surprise_mean4, earn_timing, earn_hist_absr, beat_streak, eps_yoy	밤사이 발표는 갭에 이미 반영(실적일 갭이 평소의 8배), 나머지는 효과 없음
애널리스트	an_n30, an_up30, an_down30, an_raise30, an_lower30, an_tgtchg30, an_tgt_gap, an_now_n, an_now_net, an_init30, an_reit30, an_firms30, an_init_now, an_now_tgtchg, an_init_tgt_gap	밤사이 의견은 갭에 반영, 나머지는 효과 없음

묶음	피쳐	뺀 이유
달력	gap_days, dow	dow 는 기준은 통과했지만 우연 수준 (섞은 가짜 피쳐 최대 +0.008), 근거 약함

- 모두 gap_z 규칙에 세 가지 방식으로 붙여 봤고, 가장 좋았던 것도 +0.004 이하 또는 우연 수준.
- vol_5_20 (+0.005, 3폴드)은 ext_range_z 와 함께 넣으면 train 이 가중치 0 을 골라서 뺌.
- 피쳐별 숫자는 [work/b/exp/results.md](#) 와 [cache/exp_gapfeat_all_summary.csv](#) 에 있음.

4. 선택 이유

왜 gap_z 인가

- 정답 수익률(전일 증가 → 당일 증가)에 밤사이 갭이 들어 있고, 9:30 에 보이는 시간외 갭이 전체 분산의 약 30% 를 설명함.
- 같은 1% 갭이라도 평소 2% 움직이는 종목과 0.5% 움직이는 종목은 의미가 다름 → 자기 변동성으로 나눔.
- 분모 9가지(vol5, vol20, vol60, atr14, $\sqrt{\text{vol20} \cdot \text{vol60}}$, $\text{vol20}^{0.5 \cdot 1.5}$, 시장 갭 뺀 것 등) 중 vol20 이 가장 좋음.
- 원래 갭 규칙 대비 +0.016, 4폴드 모두 상승 (+0.011 +0.033 +0.017 +0.003).

왜 ext_range_z 인가

- 의미: 시간외에 크게 출렁이다 도착한 갭은 체결이 적은 시간외 잡음일 가능성이 큼 → 덜 믿음.
- 4폴드 모두 상승 (+0.009 +0.006 +0.002 +0.004, 실험 기준. 팀 기준 경계 후보로는 +0.002 +0.005 +0.001 +0.003), train 이 고른 β 가 4폴드 모두 음수.
- **가중치를 학습 없이 0.2 로 고정해도 4폴드 모두 상승** → 데이터에 맞춘 결과가 아님.
- 6차(더하기)에서 먼저 발견 → 7차(곱하기)에서 재확인 → 10차(미리 정한 조합)에서 다시 1위.
- gap_z 와 순위상관 0.00 (겉치름 없음).
- 한계: 효과가 작음(+0.005). 우연과 확실히 구분된다고 말하기엔 부족해서 "작지만 일관된 개선"으로 봄.

왜 나머지는 뺐나

1. **방향 정보는 갭뺀:** 갭 계열이 아닌 피쳐의 방향 IC 는 최대 ± 0.05 (gap_z 0.30). 갭이 아닌 피쳐 하나로 만든 규칙 은 score 0.00~0.05.
2. **크기 피쳐는 점수로 안 바뀜:** atr14·vol·실적의 크기 IC 는 0.20~0.29 로 강함. 하지만 상승 대신 급상승으로 한 칸 올려 찍을 때, 맞으면(정답 급상승) 별점 4가 줄고 틀리면(정답 급하락) 별점 28이 늘어남 → 손실이 이득의 7배. 방향을 모르는 종목을 급등락으로 올리면 손해.
3. **밤사이 정보는 갭에 이미 있음:** 실적·애널리스트 밤사이 피쳐는 train 이 $\beta=0$ 을 고름. 실적일 갭 중간값은 평소 의 8배.
4. **갭 이후 움직임도 갭이 얇:** 9:00 가격 → 종가의 남은 움직임은 혼자 튼 갭일수록 되돌려짐 (순위상관 -0.09, 4기 간 모두 음수). 그러나 규칙 경계가 이미 반영하고 있어서 따로 넣으면 하락.
5. **여러 개를 넣으면 무너짐:** train 안에서는 피쳐를 늘릴수록 오르지만(3개 조합 +0.03~0.09) 다음 60일에서는 떨어짐(-0.013). 고른 피쳐가 폴드마다 다르고(시장 5일 수익률은 폴드마다 부호가 바뀜), 진짜 피쳐로 고른 조합과 섞은 가짜로 고른 조합의 결과가 같은 수준.

시도한 결합 방식 (모두 gap_z 규칙 이하)

방식	4폴드 평균
LightGBM 다중분류 + B 피쳐 26개 (+ 급등락 34% 디코딩)	0.417
방향 모델 + 크기 모델 2단계	0.411 ~ 0.419
gap_z 규칙과 LightGBM 섞기	섞을수록 하락
차례로 추가 (train 내부 검증, 최대 6개)	0.428

방식	4폴드 평균
Ridge (gap_z + 75개 × 3형태)	0.411
LightGBM 회귀 (gap_z 단조 제약 + 75개)	0.385
미리 정한 6개를 경제적 근거·부호 고정으로 쌓기	0.437 ~ 0.444 (ext_range_z 하나가 최고)
2개 조합 66가지, 3개 조합 220가지 전부 (train 내부 검증으로 고름)	0.438 / 0.425
규칙 모양 바꾸기 (비대칭 경계, 촘촘한 경계, 최근 기간, 부트스트랩, 구간 표)	0.433 ~ 0.442, 일관된 개선 없음

5. 팀 피처 규칙 확인 (work/b/features/check_rules.py)

규칙	확인 방법	결과
1. day 로만 꺼냄	소스 검사: <code>day.daily()</code> , <code>day.price()</code> 만 씀, <code>ds.table()</code> 없음	통과
2. <code>build(day)</code> → symbol + 피처, 종목당 한 줄	15일 실행: <code>[symbol, gap_z, ext_range_z]</code> , 종목 중복 없음. <code>predict</code> 는 <code>day.symbols</code> 전부 한 번씩, label 0~4	통과
3. <code>predict</code> 에서 <code>day.y</code> 안 씀	소스 검사 + guard 아래 <code>predict</code> 실행	통과
4. Reddit score-n_comments 안 씀	Reddit 자체를 안 씀	통과
5. 종목 이름-ID 안 씀	50종목 이름이 코드에 없음, 피처는 변동성으로 나눈 숫자뿐	통과
6. 정규화·임계값은 train 에서만 fit	λ·중앙값·표준편차·경계를 넘겨받은 train 날짜로만 계산, 같은 입력 → 같은 값, train-val 날짜 안 겹침	통과
7. <code>src/model.py</code> 안으로	저장소 복사본의 <code>src/model.py</code> 에 붙여 넣고 <code>main.py check</code> (전체 종목, 20종목만) → 형식 확인 완료. 외부 import 는 json-numpy-pandas 뿐	통과
8. 누수 검사	<code>check_no_leak(build_gapz)</code> , <code>check_no_leak(predict)</code> 각 40일	통과

학습용 `build_table()` / `fit()` 은 정답(`day.y`)을 읽음 — 학습이라 정상이고, guard 를 씌우면 바로 `LeakError` 가 나서 장치가 제대로 막는 것도 확인함.

6. 다른 파트에 전하는 것

- 모델을 쓰더라도 **gap_z 규칙 + ext_range_z (0.447)** 를 넘는지를 기준으로 봐 주세요.
- 뉴스·Reddit(C) 피처는 **gap_z 규칙 위에 없는 형태**로 시험하면 "갭이 모르는 방향 정보"를 보태는지 바로 보입니다. 확인해 볼 질문: 뉴스 없이 혼자 튜넬 갭이 뉴스 있는 갭보다 더 많이 되돌려지는가.

참고 파일

- 전달용 코드: `work/b/features/gapz_rule.py` — 피처 계산·학습·예측 한 파일 (numpy, pandas 만, `src/model.py` 에 붙여 넣기 가능). 확인: `work/b/features/check_gapz_rule.py`(점수 재현), `work/b/features/check_rules.py`(팀 피처 규칙)
- 피처 코드: `work/b/features/features_b.py` (`build_b`, `build_b_extra`), 새 피처: `work/b/exp/builders.py`(`b_v3`, `b_v4`, 과거 결과 피처), `work/b/exp/common.py`(`new_*`)
- 실험 기록: `work/b/exp/results.md` (1~12차 전체 표)
- 실험 코드: `work/b/exp/` (r01 ~ r12, 차수별 한 파일. 목록은 `work/b/exp/README.md`)